Segmentasi Penumpang Transjakarta Menggunakan Algoritma K-Means Clustering

Teresa Yuardy
Fakultas Teknologi Informasi
Universitas Tarumanagara
Jakarta, Indonesia
teresa.825240031@stu.untar.ac.id

Abstrak

Simpul integrasi antarmoda memegang peranan krusial dalam mendukung mobilitas komuter di DKI Jakarta. Namun, fluktuasi volume penumpang yang dinamis pada jam sibuk kerap menimbulkan tantangan operasional dan penumpukan massa di halte Transjakarta, terutama pada wilayah yang berperan sebagai simpul transit. Penelitian ini bertujuan untuk mengidentifikasi dan menganalisis segmentasi perilaku penumpanh Transjakarta berdasarkan karakteristik demografi dan pola transaksional harian. Metode penelitian yang diterapkan memanfaatkan pendekatan *Big Data Analytics* melalui algoritma *K-Means Clustering* terhadap data transaksi pada bulan April 2023. Atribut yang digunakan meliputi waktu *tap in* kartu, usia, dan jenis kelamin penumpang, yang sebelumnya telah dioptimalkan melalui tahap pra-pemrosesan data. Hasil pemodelan menghasilkan tiga *cluster* optimal berdasarkan minimalisasi *Euclidean Distance* terdekat. *Cluster* 0 mengidentifikasi kelompok pekerja laki-laki (rata-rata usia 39 tahun) dengan pola keberangkatan pagi. Sementara itu, *cluster* 1 dihuni oleh penumpang perempuan (rata-rata usia 33 tahun) yang aktif melakukan perjalanan pulang-pergi pada jam sibuk pagi dan sore. Di lain sisi, *cluster* 2 menangkap karakteristik para pekerja laki-laki yang pulang pada sore hari, berbanding terbalik dengan *cluster* 0. Analisis spasial menunjukkan pergerakan penumpang laki-laki didominasi oleh koridor penyangga lintas wilayah, sedangkan penumpang perempuan berpusat pada rute pengumpan (*feeder*) dan Mikrotrans. Temuan ini memberikan kontribusi ilmiah bagi pengembangan manajemen transportasi berbasis data.

Kata Kunci—*K-Means, Cluster, Transjakarta, Penumpang, Big Data*

I. PENDAHULUAN

Sejak awal peradaban, mobilitas manusia tidak pernah lepas dari peran krusial transportasi. Secara etimologi, istilah transportasi berasal dari bahasa Latin, yaitu *"trans"* yang memiliki arti sebrang dan *"portare"* berarti mengangkut [1]. Menyadari fungsi transportasi sebagai sarana penting bagi masyarakat guna memperlancar distribusi barang dan manusia, pemerintah daerah kawasan Jabodetabek menghadirkan Transjakarta sebagai solusi strategis [2].

Di kawasan metropolitan seperti Jakarta, kebutuhan akan sarana transportasi publik memegang peranan yang sangat penting. Implementasi sistem BRT (*Bus Rapid Transit*) melalui layanan Transjakarta menjadi representasi konkret komitmen pemerintah dalam mentransformasi transportasi massal, sekaligus meminimalisir ketergantungan masyarakat terhadap penggunaan kendaraan pribadi. Langkah strategis ini diharapkan dapat menciptakan ekosistem urban yang lebih ramah lingkungan, inklusif, dan berkelanjutan [3].

Tingginya minat masyarakat dalam memanfaatkan layanan Transjakarta didorong oleh beberapa faktor keunggulan yang ditawarkan. Kondisi kemacetan lalu lintas yang parah di wilayah Jakarta bertindak sebagai faktor pendorong utama (*push factor*) bagi masyarakat untuk beralih ke transportasi publik ini. Keberadaan jalur khusus Transjakarta juga memberikan keuntungan berupa efisiensi waktu tempuh yang lebih cepat daripada kendaraan pribadi, khususnya selama waktu sibuk. Selain itu, Transjakarta memiliki kapasitas angkut penumpang yang besar dalam sekali perjalanan, ditambah dengan jaringan rute luas dan mencakup berbagai penjuru kota, menjadikannya transportasi dengan tingkat aksesibilitas tinggi bagi masyarakat [4].

Selain keunggulan waktu, terdapat faktor lain yang membuat masyarakat memilih untuk memanfaatkan layanan Transjakarta, yaitu tarif tiket yang sangat terjangkau. Masyarakat cukup mengeluarkan biaya sebesar Rp3.500 untuk sekali perjalanan. Guna mendorong pergerakan yang lebih awal, pihak manajemen menerapkan tarif khusus sebesar Rp2.000 bagi pengguna yang melakukan *tap in* sebelum pukul 07.00 WIB [5]. Skema penetapan harga ini menjadikan Transjakarta sebagai transportasi alternatif yang jauh lebih hemat jika dibandingkan dengan biaya operasional kendaraan pribadi atau taksi.

Namun, berbagai hambatan operasional di lapangan masih sering kali mendegradasi mutu layanan yang diberikan. Permasalahan klasik seperi waktu tunggu armada (*headway*) yang terlalu lama, keterbatasan infrastruktur penunjang di halte, hingga minimnya tingkat kenyamanan penumpang dalam bus masih menjadi sorotan tajam [6]. Oleh sebab itu, upaya pembenahan dan optimalisasi kualitas performa Transjakarta menjadi agenda yang mendesak guna menjamin terciptanya pemerataan akses mobilitas yang berkeadilan bagi seluruh lapisan masyarakat.

Sebagai kota metropolitan, Jakarta dituntut untuk mampu menyelenggarakan pembangunan tata ruang yang terintegrasi guna meningkatkan kesejahteraan masyarakat. Salah satu manifestasi dari perencanaan sistem transportasi berkelanjutan adalah pengembangan kawasan berbasis TOD (*Transit-Oriented Development*). TOD merupakan sebuah konsep tata ruang dan pembangunan wilayah urban yang menghubungkan jaringan transportasi ramah lingkungan dengan dinamika sosial-ekonomi guna menciptakan ekosistem kota berkelanjutan [7]. Kawasan Blok M merupakan hub komersial strategis dengan aksesibilitas tinggi yang mempertemukan berbagai moda angkutan umum, mulai dari terminal bus kota, jalur khusus Transjakarta, hingga MRT (*Mass Rapid Transit*) [8].

Meskipun demikian, potensi tersebut belum mampu menarik minat masyarakat secara optimal akibat buruknya integrasi antarmoda dan konektivitas jalur pejalan kaki di

kawasan Blok M. Ketidakpaduan fasilitas untuk melakukan transit mendorong masyarakat untuk tetap mengandalkan kendaraan pribadi, sehingga memicu kemacetan parah pada jam sibuk, khususnya di Jalan Panglima Polim dan Jalan Iskandarsyah Raya [9]. Imbas dari kepadatan tersebut tercermin dari penurunan kecepatan yang signifikan pada sore hari.

Hambatan mobilitas akibat kemacetan di sepanjang koridor luar tersebut secara langsung berpengaruh pada penurunan kualitas pelayanan di dalam simpul transit itu sendiri. Penelitian terdahulu yang dilakukan oleh Firdaus dkk. mengonfirmasi bahwa Transjakarta masih menghadapi kendala terkait penumpukan penumpang (*overcrowded*) yang ekstrem serta waktu tunggu armada yang lama akibat ketidakpastian arus lalu lintas [10]. Meskipun penelitian tersebut telah mencoba memetakan preferensi dan keluhan pengguna, metodologi yang digunakan masih berbasis pada penyebaran kuesioner konvensional seperti QFD (*Quality Function Deployment*) dan IPA (*Importance-Performance Analysis*).

Pendekatan berbasis survei konvensional memiliki keterbatasan laten, di mana data yang dikumpulkan mengandalkan perspektif subjektif, bersifat statis, serta kurang mampu menangkap volume data yang masif maupun fluktuasi pergerakan di lapangan secara dinamis. Guna mengisi kesenjangan metodologis tersebut, penelitian ini hadir dengan memperkenalkan pendekatan baru, yaitu *Big Data Analytics* menggunakan algoritma *Machine Learning K-Means Clustering*. Melalui pemanfaatan aset data transaksi digital (*tap in*) penumpang di koridor terkait, pola pemusatan dan karakteristik komuter dapat diklasifikasikan secara otomatis berdasarkan dimensi waktu, usia, dan jenis kelamin. Pendekatan ini diharapkan dapat mengeliminasi unsur subjektivitas guna menghasilkan rekomendasi kebijakan alokasi dan penambahan armada bus Transjakarta yang lebih objektif, presisi, dan adaptif.

II. METODE

A. Sumber dan Pengumpulan Data

Metode penelitian diawali dengan tahap pengumpulan data yang menjadi landasan utama analisis. Data yang digunakan dalam penelitian ini merupakan data sekunder yang diperoleh secara legal melalui *open-source data platform*, yaitu Kaggle. Rentang waktu pengambilan data dibatasi secara spesifik pada kurun waktu sebulan penuh, yaitu selama bulan April 2023. *Dataset* yang dipilih memuat 37.000 baris data aktivitas penumpang. Terdapat 12 atribut utama yang diekstrak dan digunakan dalam penelitian ini. Penjelasan mengenai masing-masing atribut disajikan pada Tabel 1.

Tabel 1. Penjelasan Atribut

No.	Atribut	Keterangan
1.	transID	ID transaksi dari setiap pelanggan, berperan sebagai *primary key* agar tidak ada data duplikat.
2.	payCardBank	Jenis kartu yang digunakan pelanggan untuk *tap in* dan *tap out*.
3.	payCardName	Nama pada kartu yang digunakan pelanggan.
4.	payCardSex	Jenis kelamin pelanggan.
5.	payCardBirthDate	Tahun kelahiran pelanggan.
6.	corridorID	Kode rute Transjakarta.
7.	corridorName	Nama rute Transjakarta.
8.	tapInStopsName	Nama halte tempat pelanggan melakukan *tap in* kartu.
9.	tapInTime	Waktu pelanggan melakukan *tap in* kartu.
10.	tapOutStopsName	Nama halte tempat pelanggan melakukan *tap out* kartu.
11.	tapOutTime	Waktu pelanggan melakukan *tap out*.
12.	payAmount	Tarif yang dibayarkan pelanggan.

B. Data Preprocessing

Data Preprocessing merupakan sebuah teknik untuk mengubah data mentah menjadi format yang lebih efisien. Beberapa proses yang terjadi dalam *Data Preprocessing* adalah integrasi data, pembersihan data, transformasi data, dan reduksi data [11]. Teknik ini perlu dilakukan sebelum data diolah [12]. Pada penelitian ini, langkah pertama yang dilakukan adalah penataan struktur melalui penyelarasan nama kolom (*renaming columns*). Setelah dirapikan, dilakukan pembersihan data (*data cleaning*) dengan mengidentifikasi serta mengeliminasi nilai yang hilang (*missing value*). Selanjutnya, dilakukan transformasi data (*data transformation*) terhadap atribut yang akan digunakan.

C. Algoritma K-Means Clustering

Metode analisis utama yang diterapkan dalam penelitian ini adalah algoritma *K-Means Clustering*. *K-Means Clustering* merupakan suatu metode segmentasi data ke dalam kelompok yang berbeda. Melalui metode ini, objek yang memiliki kemiripan karakteristik akan ditempatkan pada *cluster* yang sama, sedangkan objek dengan karakteristik berbeda akan dipisahkan dalam *cluster* yang lain [13].

Dalam konteks transportasi, metode ini dimanfaatkan untuk mengelompokkan penumpang berdasarkan karakteristik tertentu. Penggunaan algoritma *K-Means Clustering* diharapkan dapat menghasilkan informasi mengenai pola penggunaan transportasi yang terstruktur guna mendukung pengambilan keputusan yang lebih akurat [14]. Demi mencapai tujuan tersebut, implementasi *K-Means Clustering* perlu melewati beberapa tahapan sistematis yang mengatur bagaimana data dialokasikan dalam pusat kelompok.

Implementasi algoritma *K-Means Clustering* dilakukan melalui proses iteratif yang dimulai dari penetapan jumlah *cluster* yang ingin dibentuk sebanyak k = 3. Selanjutnya dilakukan inisialisasi posisi pusat *cluster* (*centroid*) secara acak dan menghitung jarak setiap data terhadap masing-masing *centroid* menggunakan rumus *Euclidean Distance*. Terakhir, data diklasifikasi berdasarkan jarak terkecil dengan *centroid* dan pembaruan posisi *centroid* secara berkala hingga mencapai kondisi konvergensi [15].

D. Analisis Statistik Deskriptif dan Distribusi Frekuensi

Tahap akhir dari metode penelitian ini adalah melakukan analisis lanjut terhadap karakteristik masing-masing kelompok (*cluster*) yang telah terbentuk melalui algoritma *K-Means*. Proses ini didukung oleh dua pendekatan utama, yaitu

analisis statistik deskriptif dan distribusi frekuensi. Kedua pendekatan ini dipilih dengan tujuan mentransformasikan angka dari koordinat pusat *cluster* menjadi narasi perilaku penumpang yang mudah dipahami.

Statistik deskriptif merupakan jenis analisis yang biasa digunakan untuk menyajikan data. Statistik deskriptif sering kali digunakan sebagai langkah pertama dalam merapikan data sebelum dilakukan analisis yang lebih lanjut [16]. Dalam penelitian ini, statistik deskriptif diterapkan sebagai alat untuk merapikan dan meringkas data yang telah dikelompokkan oleh algoritma *K-Means*. Proses penyajian data dilakukan dengan menghitung nilai pemusatan data pada setiap *cluster*, meliputi perhitungan nilai rata-rata (*mean*) untuk memperlihatkan metrik usia dan waktu transaksional, serta nilai modus untuk menunjukkan dominasi kategori jenis kelamin.

Sementara itu, analisis distribusi frekuensi merupakan sebuah metode penyusunan atau pengaturan rangkaian data ke dalam kelas-kelas tertentu berdasarkan kuantitas (angka) atau kualitas (kategori) [17]. Pada penelitian ini, distribusi frekuensi kuantitatif digunakan untuk menyusun sebaran data penumpang berdasarkan variabel kuantitas, yaitu fluktuasi waktu *tap in* dan rentang usia pelanggan, yang kemudian divisualisasikan menggunakan grafik histogram dan poligon. Di sisi lain, distribusi frekuensi kualitatif diterapkan untuk menyusun rangkaian data berdasarkan kualitas atau kategori, yakni pengelompokan proporsi penumpang berdasarkan jenis kelamin pada masing-masing *cluster*.

III. Hasil dan Pembahasan

Sebelum dilakukan pemodelan *Unsupervised Machine Learning* menggunakan algoritma *K-Means Clustering*, *dataset* transaksi Transjakarta pada bulan April 2023 yang diperoleh dari platform Kaggle ini perlu melewati rangkaian pra-pemrosesan data. Tahap pertama dalam pra-pemrosesan adalah penyelarasan nama kolom (*renaming columns*).

```
Index(['transID', 'payCardBank', 'name', 'gender', 'birthDate', 'corridorID',
       'corridorName', 'tapInStopsName', 'tapInTime', 'tapOutStopsName',
       'tapOutTime', 'payAmount'],
      dtype='object')
```

Gambar 1. Renaming Columns

Gambar 1 menunjukkan nama-nama kolom yang telah diberi nama baru. Terdapat 3 kolom yang diubah namanya, yaitu payCardName menjadi name, payCardSex menjadi sex, dan payCardBirthDate menjadi birthDate. Tujuan perubahan ini adalah untuk membuat nama kolom lebih representatif dan konsisten guna memudahkan pemanggilan variabel dalam kode Python.

```
Terdapat 0 baris duplikat
```

Gambar 2. Pengecekan Data Duplikat

Selanjutnya, dilakukan pengujian data duplikat yang menunjukkan bahwa terdapat 0 baris data duplikat dalam *dataset* (lihat Gambar 2). Ketiadaan data duplikat dipengaruhi oleh kolom transID yang berfungsi layaknya *primary key* dalam *dataset*. Setiap baris transaksi memiliki kode identifikasi unik yang isinya berbeda satu sama lain, sehingga secara sistematis mencegah terjadinya redundansi dan menjamin seluruh aspek integritas data terpenuhi.

	Missing	Percentage
corridorName	1930	0.050923
tapOutStopsName	1344	0.035462
tapOutTime	1344	0.035462
corridorID	1257	0.033166
payAmount	1007	0.026570
name	0	0.000000
payCardBank	0	0.000000
transID	0	0.000000
gender	0	0.000000
birthDate	0	0.000000
tapInStopsName	0	0.000000
tapInTime	0	0.000000

Gambar 3. Missing Values

Langkah selanjutnya adalah mendeteksi keberadaan data yang hilang (*missing values*). Gambar 3 menunjukkan jumlah baris pada kolom tertentu yang memiliki *missing value* beserta persentasenya. *Missing value* adalah suatu kondisi di mana terdapat nilai yang hilang atau tidak lengkap pada satu atau beberapa kriteria data [18]. Hilangnya beberapa bagian data akan memengaruhi tingkat akurasi dari data yang diproses. Selain itu, *missing value* menyebabkan pendugaan parameter tidak efisien akibat ukuran data yang berkurang [19].

Berdasarkan *dataset*, terdapat 5 kolom yang memiliki *missing value*, yaitu corridorName (5,09%), tapOutStopsName (3,54%), tapOutTime (3,54%), corridorID (3,31%), dan payAmount (2,65%). Algoritma *K-Means Clustering* berbasis pada perhitungan yang sensitif terhadap nilai kosong, oleh sebab itu, diputuskan untuk menerapkan metode *complete case analysis* dengan menghapus seluruh baris yang mengandung *missing value*. Volume *dataset* yang tergolong sangat besar (*Big Data*) membuat eliminasi baris tidak mengurangi sifat representatif dari populasi penumpang.

	Missing	Percentage
transID	0	0.0
payCardBank	0	0.0
name	0	0.0
gender	0	0.0
birthDate	0	0.0
corridorID	0	0.0
corridorName	0	0.0
tapInStopsName	0	0.0
tapInTime	0	0.0
tapOutStopsName	0	0.0
tapOutTime	0	0.0
payAmount	0	0.0

Gambar 4. Missing Values yang Telah Dihapus

Gambar 4 menunjukkan sudah tidak ada kolom yang memiliki *missing value*. Secara umum, terdapat dua pendekatan utama untuk mengatasi *missing value*, yaitu

penghapusan data dan mengganti data yang hilang dengan estimasi tertentu (*imputation*) [20]. Penulis memilih untuk melakukan penghapusan untuk menjaga integritas dan keaslian data, sehingga cluster yang terbentuk murni berdasarkan karakteristik penumpang tanpa adanya intervensi data buatan.

Tahap berikutnya adalah transformasi data, di mana atribut tapInTime diekstrak secara spesifik untuk diambil komponen jamnya saja ke dalam format numerik dengan rentang indeks 0 hingga 24. Atribut gender (sebelumnya payCardSex) yang semula berbentuk teks ditransformasi dengan menggunakan metode penyadian (*encoding*) menjadi representasi biner angka 0 untuk laki-laki dan 1 untuk perempuan. Terakhir, atribut usia penumpang dikonstruksikan dengan menghitung selisih tahun dari atribut birthDate pada *dataset*. Ketiga kolom tersebut dipilih untuk diproses lebih lanjut menggunakan algoritma *K-Means Clustering*.

Proses *clustering* dilakukan dengan menetapkan jumlah *cluster* sebesar k = 3 menggunakan acuan *random state* = 42. Parameter *random state* = 42 digunakan untuk menentukan *pseudo-random number generator seed*. Tujuannya adalah untuk memastikan konsistensi inisialisasi *centroid* awal pada algoritma *K-Means*, sehingga proses *clustering* dapat direplikasi dengan hasil yang konsisten secara berulang.

Tabel 2. Centroid Karakteristik Penumpang

Atribut	***Cluster* 0**	***Cluster* 1**	***Cluster* 2**
Waktu (Time)	6.93 (06:56 WIB)	12.57 (12:34 WIB)	17.83 (17:50 WIB)
Usia (Age)	39.00 Tahun	33.01 Tahun	38.98 Tahun
Jenis Kelamin (Gender)	0 (Laki-laki)	1 (Perempuan)	0 (Laki-laki)

Nilai *centroid* yang tersaji pada Tabel 2 tidak ditentukan secara instan, melainkan dikonstruksikan secara objektif melalui proses komputasi iteratif algoritma *K-Means* hingga mencapai kondisi konvergensi matematis. Proses penentuan *centroid* diawali dengan menginisialisasi tiga titik pusat acak di dalam ruang dimensi berdasarkan parameter *random state* = 42 yang telah dikunci. Selanjutnya, algoritma bekerja secara repetitif dengan mengukur jarak seluruh baris data transaksi terhadap pusat acak tersebut, mengelompokkan data ke pusat terdekat, dan memperbarui posisi *centroid* berdasarkan perhitungan nilai rata-rata dari atribut Time, Age, dan Gender yang berada di kelompok baru tersebut.

Angka akhir yang terbentuk pada posisi konvergen ini yang merepresentasikan titik berat karakteristik perilaku setiap segmentasi penumpang secara nyata, di mana alokasi klasifikasi setiap baris objek data mentah ke dalam cluster-cluster tersebut didasarkan pada minimalisasi jarak geometris terkecil. Selanjutnya, algoritma *K-Means Clustering* akan mengukur kedekatan antara sebuah baris data dengan *centroid* menggunakan rumus *Euclidean Distance*.

$$d(x,y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2} \qquad (1)[21]$$

Persamaan (1) merupakan rumus *Euclidean Distance* yang digunakan untuk mengukur kedekatan sebuah baris data dengan *centroid*. *d(x,y)* merupakan jarak antara objek *x* dan *y*, sedangkan *n* menyatakan jumlah dimensi data. Adapun x_i dan y_i merepresentasikan nilai fitur ke-*i* pada objek *x* dan *y*.

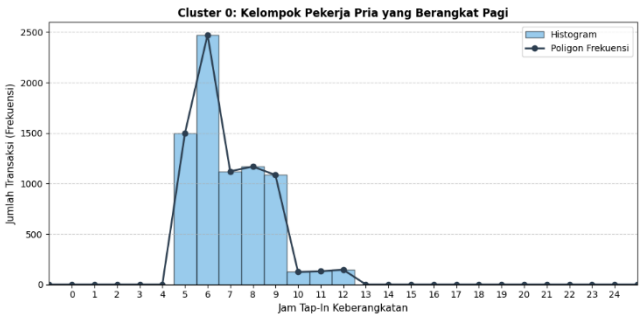
Tabel 3. Hasil Clustering (5 Baris Pertama)

Time	Age	Gender	corridorID	Cluster
5	18	0	5	0
5	29	1	6C	1
5	34	1	R1A	1
5	48	1	11D	1
6	44	0	12	0

Tabel 3 menyajikan lima baris pertama pada *dataset* yang telah dikelompokkan ke dalam *cluster*. Sebagai bahan pengujian, penulis akan mengambil baris pertama data (5, 18, 0) dan memasukkannya ke dalam rumus *Euclidean Distance* untuk melihat jarak antar data dengan *centroid* masing-masing *cluster*. Sebelumnya, data telah dinormalisasi di Python dengan menggunakan MinMaxScaler(), sehingga koordinat akhir pada data pertama menjadi (0.217, 0.043, 0.000). Kemudian dengan cara yang sama, koordinat *centroid* dalam sistem Python menjadi (0.301, 0.343, 0.000) untuk *centroid* 0, (0.547, 0.257, 1.000) untuk *centroid* 1, dan (0.775, 0.343, 0.000) untuk *centroid* 2.

Berdasarkan perhitungan yang telah dilakukan dengan rumus *Euclidean Distance*, diperoleh hasil jarak data pertama ke masing-masing *cluster*, yaitu sebesar 0.311 ke *cluster* 0, 1.075 ke *cluster* 1, dan 0.634 ke *cluster* 2. Setelah hasil didapatkan, algoritma *K-Means* akan membandingkan dan mengambil nilai jarak terkecil. Oleh sebab itu, sistem Python secara otomatis mengambil nilai jarak terkecil dari hasil perhitungan, yaitu 0.311 dan memasukkan data penumpang pertama ke *cluster* 0.

Proses selanjutnya adalah memanfaatkan analisis statistik deskriptif dan distribusi frekuensi untuk menerjemahkan angka-angka *cluster* menjadi narasi profil perilaku penumpang. *Cluster* 0 diidentifikasi sebagai kelompok pekerja laki-laki dengan keberangkatan pagi. Berdasarkan hasil statistik deskriptif, kelompok ini memiliki waktu transaksional yang sangat awal, yaitu pukul 06:56 WIB dengan rata-rata usia penumpang 39 tahun. Karakteristik ini diperkuat melalui Gambar 5 yang menyajikan grafik histrogram dan poligon untuk *cluster* 0.

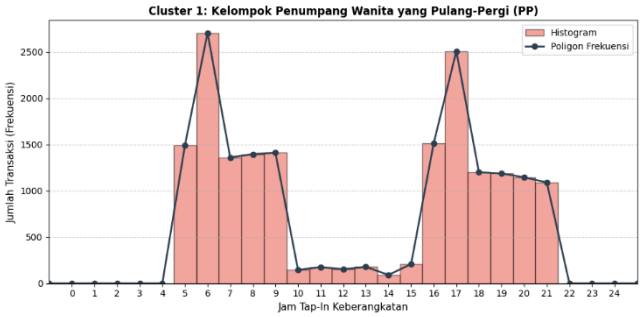


Gambar 5. Grafik Histogram dan Poligon Cluster 0

Temuan ini mengonfirmasi bahwa *cluster* 0 merepresentasikan pergerakan penumpang laki-laki yang melakukan mobilitas harian secara konsisten di awal waktu pagi untuk mengejar jam masuk kantor, tarif lebih murah,

atau aktivitas ekonomi di wilayah padat guna menghindari kemacetan.

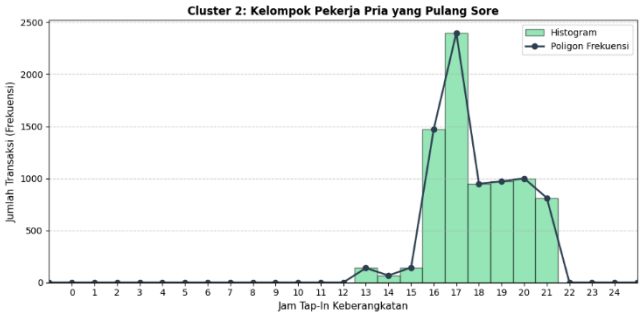
Cluster 1 mengonfirmasi profil kelompok penumpang perempuan dengan pola pergerakan dua puncak. Secara deskriptif, nilai rata-rata waktu untuk *cluster* ini menunjukkan angka 12:34 WIB dengan rata-rata usia lebih muda, yaitu 33 tahun. Meskipun angka rata-rata mengindikasikan pergerakan siang hari, analisis distribusi frekuensi pada Gambar 6 membongkar sebuah fenomena unik berupa kurva dua puncak yang simetris.



Gambar 6. Grafik Histogram dan Poligon Cluster 1

Lonjakan volume transaksi masif terjadi pada pukul 06.00 WIB dan pukul 17.00 WIB. Paradoks nilai rata-rata siang hari murni merupakan titik tengah geometris dari dua waktu (*rush hours)* sibuk tersebut. Hal ini membuktikan bahwa *cluster* 1 merupakan representasi dari kelompok perempuan produktif yang melakukan perjalanan pulang-pergi (PP) dari rumah menuju tempat aktivitas dan kembali pada hari yang sama.

Cluster 2 diklasifikasikan sebagai kelompok pekerja laki-laki dengan perjalanan pulang sore, yang secara demografis merupakan kebalikan dari karakteristik *cluster* 0. Kelompok ini memiliki rata-rata usia 39 tahun dengan waktu transaksional pukul 17:50 WIB. Sebagaimana tersaji pada Gambar 7, grafik histrogram dan poligon *cluster* 2 menunjukkan pola pergerakan tunggal yang melonjak tajam menjelang malam hari.



Gambar 7. Grafik Histogram dan Poligon Cluster 2

Pola visual ini menegaskan arus balik mobilitas pekerja laki-laki yang pulang setelah jam operasional kantor berakhir untuk kembali ke kediaman masing-masing, sehingga membentuk siklus komuter harian yang berbanding terbalik dengan *cluster* 0.

Kemudian untuk melihat keterkaitan pola pergerakan penumpang dengan ruang kota, dilakukan analisis tabulasi silang (*crosstab*) antara rute Transjakarta dengan *cluster* yang terbentuk. Hasil ekstraksi terhadap lima koridor dengan kepadatan tertinggi pada masing-masing *cluster* disajikan pada Tabel 4.

Tabel 4. Lima Koridor Terdapat Berdasarkan Cluster

Peringkat	*Cluster* 0	*Cluster* 1	*Cluster* 2
1	S21 (130 data)	T11 (211 data)	11Q (122 data)
2	11Q (116 data)	9D (210 data)	S21 (119 data)
3	1T (110 data)	2E (205 data)	1T (110 data)
4	JIS3 (105 data)	JAK.112 (195 data)	JIS3 (100 data)
5	JAK.11 (97 data)	JAK.36 (187 data)	JAK.11 (96 data)

Berdasarkan Tabel 4, terlihat sinkronisasi spasial yang sangat kuat antara *cluster* 0 dan *cluster* 2. Rute Transjakarta S21 (Ciputat - Blok M), 11Q (Kampung Melayu - Pulo Gebang via BKT), serta 1T (Cibubur - Blok M) secara konsisten menduduki peringkat teratas pada kelompok penumpang laki-laki. Hal ini menunjukkan koridor-koridor penghubung wilayah penyangga seperti Ciputat dan Cibubur menuju hub bisnis Blok M yang didominasi oleh pekerja laki-laki dengan pola keberangkatan pagi dan kepulangan sore yang teratur.

Sementara itu, *cluster* 1 berpusat pada rute-rute seperti T11 (Poris Plawad - Bundaran Senayan), 9D (Pasar Minggu - Tanah Abang), 2E (Pulo Gadung - Rusun Rawa Bebek), serta layanan Mikrotrans (JAK.112 dan JAK.36). Keberadaan angkutan pengumpan dan Mikrotrans mendominasi pergerakan perempuan pada jam-jam sibuk mengindikasikan pentingnya penguatan kualitas keamanan, fasilitas ramah *gender*, serta kepastian *headway* bus pada rute-rute pengumpan tersebut guna mengakomodasi karakteristik pergerakan dua puncak dari penumpang perempuan di wilayah perkotaan Jakarta.

Terkait temuan spasial mengenai lima koridor terpadat pada masing-masing cluster, penulis memiliki beberapa rekomendasi strategis dalam mengoptimalkan manajemen operasional Transjakarta ke depannya. Disarankan adanya kebijakan sinkronasi jadwal armada berupa pemusatan kuantitas bus secara masif pada jendela waktu sibuk (*rush hours)* pada rute-rute penghubung di *cluster* 0 dan *cluster* 2, yakni sebelum pukul 06.30 WIB untuk keberangkatan pagi dan pukul 17.30 WIB untuk arus kepulangan sore.

Sementara itu, untuk mengakomodasi karakteristik unik *cluster* 1 yang berpusat pada rute pengumpan, intervensi ke depan harus difokuskan pada jaminan kepastian waktu tunggu (*headway*), peningkatan kapasitas tampung intermoda, serta penguatan fasilitas ramah gender dan aspek keamanan yang ketat. Melalui implementasi manajemen armada berbasis karakteristik segmentasi penumpang ini, Transjakarta diharapkan dapat secara akurat mengurai penumpukan massa di wilayah transit sekaligus meningkatkan efisiensi mobilitas penumpang lintas daerah secara berkelanjutan.

IV. KESIMPULAN DAN SARAN

Penelitian ini berhasil memetakan segmentasi perilaku penumpang Transjakarta menggunakan pendekatan *Big Data Analytics* berbasis algoritma *K-Means Clustering*. Melalui serangkaian tahapan pra-pemrosesan data yang sistematis seperti penyelarasan kolom, pembersihan *missing value*, serta rekayasa fitur untuk mengonstruksikan variabel waktu, usia,

dan jenis kelamin, puluhan ribu rekam jejak penumpang berhasil ditransformasikan ke dalam model pengelompokan non-hierarki yang optimal. Berdasarkan minimalisasi dengan rumus *Euclidean Distance*, algoritma berhasil mempartisi karakteristik mobilitas penumpang secara objektif menjadi tiga cluster utama yang memiliki homogenitas sangat tinggi di dalam kelompoknya.

Hasil analisis statistik deskriptif dan distribusi frekuensi membuktikan adanya pola pergerakan penumpang yang spesifik dan dipengaruhi oleh faktor sosio-demografis serta tata ruang kota. *Cluster* 0 merepresentasikan kelompok pekerja laki-laki yang konsisten melakukan perjalanan pagi (pukul 06:56 WIB). *Cluster* 1 menyajikan fenomena unik di mana rata-rata waktu tengah hari (pukul 12:34 WIB) sebenarnya mengonfirmasi sebaran dua puncak dari kelompok perempuan yang aktif melakukan perjalanan pulang-pergi pada jam sibuk di pagi dan sore hari. Di lain sisi, *cluster* 2 merupakan kebalikan dari *cluster* 0, yaitu kelompok pekerja laki-laki yang melakukan perjalanan pulang pada sore menjelang malam hari (17:50 WIB). Pola ini tersinkronasi kuat secara spasial, di mana koridor utama seperti S21 dan 11Q mendominasi pergerakan pekerja laki-laki, sedangkan rute pengumpan seperti T11 dan layanan Mikrotrans menjadi jalur vital bagi mobilitas penumpang perempuan.

Berdasarkan proses dan keterbatasan yang ditemui dalam pemodelan *cluster* ini, terdapat beberapa saran akademis yang dapat direkomendasikan untuk pengembangan penelitian selanjutnya. Penelitian ke depan disarankan untuk memperluas ruang lingkup analisis dengan melakukan studi komparatif antarsimpul integrasi utama lainnya di DKI Jakarta, seperti kawasan transit Dukuh Atas dan Manggarai untuk menangkap variasi pola pegerakan penumpang secara lebih makro. Selain itu, rekayasa fitur pada penelitian mendatang dapat diperkaya dengan mengintegrasikan variabel eksternal seperti faktor kondisi cuaca, fluktuasi tarif insentif khusus, hingga ketepatan jadwal kedatangan transportasi terintegrasi lainnya. Terakhir, peneliti selanjutnya dapat mengeksplorasi penggunaan algoritma *clustering* lain, seperti DBSCAN atau *Agglomerative Clustering*, untuk membandingkan tingkat akurasi serta efisiensi algoritma dalam menangani karakteristik data transaksi yang masif.

UCAPAN TERIMAKASIH

Dengan penuh rasa hormat dan ketulusan, penulis menyampaikan apresiasi dan terima kasih kepada Dr. Bagus Mulyawan S.Kom., M.M. selaku dosen pengampu mata kuliah, yang telah memberikan landasan teori, arahan akademik, serta bimbingan sejak awal perkuliahan. Ucapan terima kasih juga penulis sampaikan kepada para asisten dosen yang telah membagikan ilmu mengenai teknis penulisan kode Python selama kelas praktikum serta platform Kaggle dan kontributor *dataset* sebagai *open-source data platform*, sehingga penelitian ini dapat direalisasikan dengan baik.

REFERENSI

[1] Ni Putu Decy Arwini and I Made Juniastra, "Peran Transportasi Dalam Dunia Industri," *J. Ilm. Vastuwidya*, vol. 6, no. 1, pp. 70–77, 2023.

[2] Yuyun Aprilia, "Analisis Peningkatan Efektivitas Transportasi Umum (Transjakarta)," *Pros. Semdikjar (Seminar Nas. Pendidik. dan Pembelajaran)*, vol. 6, pp. 1598–1601, 2023.

[3] Agnes Laura Sianturi and Muhammad Isradi, "Evaluation of Operational Performance and Transjakarta Services Corridor 3F Kalideres-Gelora Bung Karno (GBK)," *Int. J. Sci. Eng. Sci.*, vol. 8, no. 8, pp. 83–89, 2024.

[4] E. Chandra and L. S. Putranto, "ANALISIS PERMINTAAN DAN KEPUASAN PENUMPANG TERHADAP PELAYANAN BUS TRANSJAKARTA KORIDOR 9," *JMTS J. Mitra Tek. Sipil*, vol. 7, no. 2, pp. 709–720, May 2024, doi: 10.24912/jmts.v7i2.27894.

[5] Y. U. Liucius, H. R. . Angkat, and L. JorgeWilliam, "TINJAUAN KEPUASAN PENGGUNA TERHADAP LAYANAN BUS TRANSJAKARTA KORIDOR 12 (TANJUNG PRIOK - PLUIT)," *JMTS J. Mitra Tek. Sipil*, vol. 7, no. 3, pp. 949–956, Aug. 2024, doi: 10.24912/jmts.v7i3.30640.

[6] A. Utami and W. K. R. Natio, "Analisis Perbandingan Waktu Perjalanan dan Biaya antara Kendaraan Pribadi dan Transjakarta menggunakan Metode PCI (Studi Kasus : TJ Koridor IX Pinang Ranti-Pluit)," *Reka Buana J. Ilm. Tek. Sipil dan Tek. Kim.*, vol. 6, no. 2, pp. 150–159, Oct. 2021, doi: 10.33366/rekabuana.v6i2.2649.

[7] S. Sarjana, "Analisis Bibliometrik Transit-Oriented Development," *War. Penelit. Perhub.*, vol. 34, no. 2, pp. 149–160, Dec. 2022, doi: 10.25104/warlit.v34i2.1816.

[8] F. Sugita, S. Herlambang, and P. Rahardjo, "STUDI POLA PERGERAKAN PENUMPANG DI TITIK TRANSIT (STUDI KASUS : STASIUN MRT BLOK M DAN TERMINAL BUS BLOK M, KEBAYORAN BARU, JAKARTA SELATAN)," *J. Sains, Teknol. Urban, Perancangan, Arsit.*, vol. 3, no. 2, p. 3277, Feb. 2022, doi: 10.24912/stupa.v3i2.12839.

[9] P. Gifarry, I. R. D. Ari, and N. Firdausiyah, "PENERAPAN KAWASAN BERORIENTASI TRANSIT DI KAWASAN TRANSIT BLOK M, JAKARTA SELATAN," *Tata Kota dan Drh.*, vol. 14, no. 2, Dec. 2022, doi: 10.21776/ub.takoda.2022.014.02.3.

[10] H. Y. Firdaus, H. Andraiko, M. Isradi, and K. M. Sudrajat, "Enhancing Transjakarta Bus Service Quality: An Educational Perspective on Urban Development and Traffic Mitigation Using QFD Method," *J. Educ. Manag. Res.*, vol. 4, no. 2, pp. 627–640, Jul. 2025, doi: 10.61987/jemr.v4i2.1016.

[11] D. Varma, A. Nehansh, and P. Swathy, "Data Preprocessing Toolkit : An Approach to Automate Data Preprocessing," *INTERANTIONAL J. Sci. Res. Eng. Manag.*, vol. 07, no. 03, Mar. 2023, doi: 10.55041/IJSREM18270.

[12] I. M. Hamdani, N. Nurhidayat, A. Karman, N. F. Adhalia H, and A. H. Julyaningsih, "Edukasi dan Pelatihan Data Science dan Data Preprocessing," *Intisari J. Inov. Pengabdi. Masy.*, vol. 2, no. 1, pp. 19–26, Jun. 2024, doi: 10.58227/intisari.v2i1.125.

[13] M. F. Daffauzan, "Analisa Penumpang Bus Transjakarta dengan Metode K-Means," *J. Comput. Sci. Inf. Syst. J-Cosys*, vol. 3, no. 2, pp. 61–64, Jul. 2023, doi: 10.53514/jco.v3i2.395.

[14] Arief Rahman Ramadhan and Anita Diana, "Penerapan Algoritma K-Means Untuk Klasterisasi Jumlah Penumpang Angkutan Umum Di Jakarta," *J. Inform. Manajemen, dan Komput.*, vol. 17, no. 2, pp. 550–558, 2025.

[15] M. Mardiansa, H. L. Sari, and P. Prahasti, "Penerapan Data Mining Untuk Mengetahui Minat Siswa Pada Pelajaran IPA Mengunakan Metode K-Means Clustering," *J. Multidisiplin Dehasen*, vol. 2, no. 4, Oct. 2023, doi: 10.37676/mude.v2i4.4749.

[16] L. D. Martias, "STATISTIKA DESKRIPTIF SEBAGAI KUMPULAN INFORMASI," *Fihris J. Ilmu Perpust. dan Inf.*, vol. 16, no. 1, p. 40, Jun. 2021, doi: 10.14421/fhrs.2021.161.40-59.

[17] A. Wahab, A. Syahid, and J. Junaedi, "Penyajian Data Dalam Tabel Distribusi Frekuensi Dan Aplikasinya Pada Ilmu Pendidikan," *Educ. Learn. J.*, vol. 2, no. 1, p. 40, Jan. 2021, doi: 10.33096/eljour.v2i1.91.

[18] W. Sudrajat and I. Cholid, "K-NEAREST NEIGHBOR (K-NN) UNTUK PENANGANAN MISSING VALUE PADA DATA UMKM," *J. Rekayasa Sist. Inf. dan Teknol.*, vol. 1, no. 2, pp. 54–63, Nov. 2023, doi: 10.59407/jrsit.v1i2.77.

[19] A. Khusaeri, "PENERAPAN TEKNIK IMPUTASI K-MEANS TERHADAP PERFORMA HASIL KLASIFIKASI ALGORITMA NAÏVE BAYES," *J. Manajamen Inform. Jayakarta*, vol. 5, no. 1, pp. 41–51, Feb. 2025, doi: 10.52362/jmijayakarta.v5i1.1765.

[20] Cindy Pramudita, Naura Aiswaraya Asri Wicaksono, Anjar Kharisma Hartiyah, Annisa Maisaroh, and Iqbal Kharisudin,

"Menangani Missing Value dengan Metode Imputasi Menggunakan Package MICE di R," *Prism. Pros. Semin. Nas. Mat.*, pp. 399–406, 2025.

[21] D. Ramdhan, G. Dwilestari, R. D. Dana, A. Ajiz, and K. Kaslani, "Clustering Data Persediaan Barang Dengan Menggunakan Metode K-Means," *MEANS (Media Inf. Anal. dan Sist.*, vol. 7, no. 1, pp. 1–9, May 2022, doi: 10.54367/means.v7i1.1826.